基於 LoRA 與強化學習之大型語言模型推理優化

RLHF / GRPO

Parameter-Efficient Fine-Tuning

Low VRAM Constraint

Xu-Lin Chen

Jie-En Liu

Xin-Chiao Tien

OUTLINE

From A to F

01

Introduction

Our Motivation

02

Related Work

Current related research

03

Methodology

Our scheme

04

Proposed Design

Research Methods

研究動機 - LLM 推理能力的缺失

傳統測試 (如 GSM8K) 顯示模型數學能力已達人類水準，但 2024 年 Apple 發布的 **GSM-Symbolic 權威研究**揭露：模型僅是「背誦模式」(Pattern Matching)，並非真正理解邏輯。

標準 GSM8K 測試

94.6%

Llama-3-8B 表面上的數學解題率

變更變數與名字後 (GSM-Symbolic)

– 65%

準確率呈現毀滅性衰退，證明缺乏 System 2 思考

* Apple Machine Learning Research (2024) - "Understanding the Limitations of Mathematical Reasoning in LLMs"

解決方向 - 強化學習的導入

純監督式微調 (SFT) 已觸碰能力天花板。根據 OpenAI o1 與 DeepSeek-R1 的最新報告，**導入強化學習引導模型生成長思維鏈 (Chain-of-Thought)** 是唯一能突破複雜邏輯瓶頸的方法。

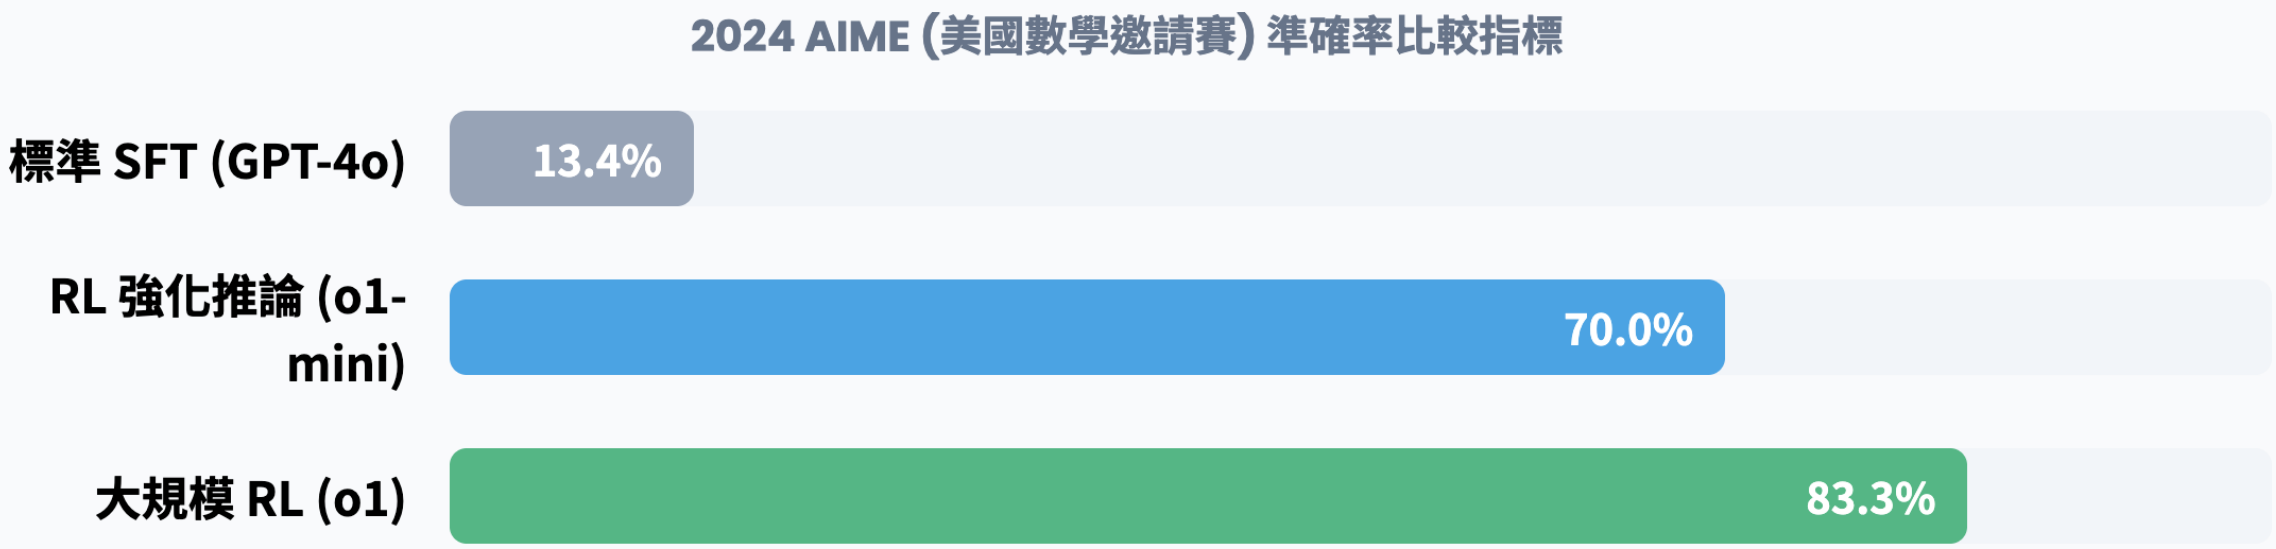

* OpenAI o1 System Card (2024) - AIME 2024 Pass@1 基準測試

當前挑戰 - 強化學習的成本問題

挑戰一：極高 VRAM 消耗

標準 PPO 演算法需同時在顯存中載入 4 個模型 (Actor, Critic, Reference, Reward Model)。對於 8B 參數模型，全參數微調將遠超學術實驗室的消費級 GPU 極限。

挑戰二：獎勵駭客 (Reward Hacking)

若依賴 LLM 作為裁判 (Reward Model) 給分，模型極易學會生成「看似合理但邏輯錯誤」的長篇大論來騙取高分，導致訓練崩潰。

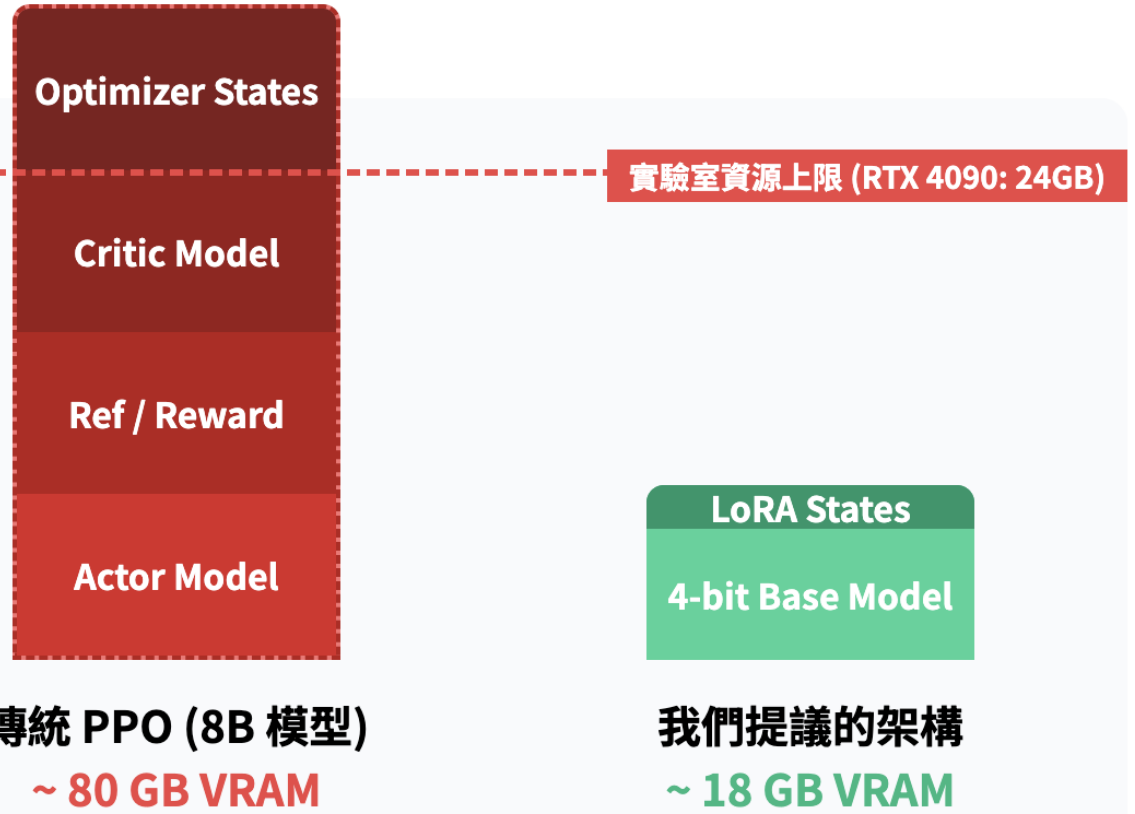

過往研究 – 當前研究與技術

本專案奠基於 DeepSeekMath 的 GRPO 理論與 Hu 等人的 LoRA 研究。我們將各主流對齊技術進行量化比較，確立本提案的利基定位。

對齊技術 (Alignment)	複雜邏輯推理提升	運算資源 (VRAM需求)	需額外訓練 Reward Model?
SFT (Supervised Fine-Tuning)	**低 (易產生幻覺)**	**低 (單一模型)**	否
PPO (Proximal Policy Optimization)	**極高**	**極高 (4個模型)**	是 (容易產生 Reward Hacking)
DPO (Direct Preference Opt.)	中等	高 (2個模型)	否 (使用離線成對數據)
Ours: GRPO + LoRA + Rule Reward	**高 (利用群體相對優勢)**	**低 (凍結主幹 + 無 Critic)**	**否 (直接使用程式/規則驗證)**

* GRPO (Group Relative Policy Optimization) 參考自 DeepSeek-R1 (2025)，透過同一 Prompt 多次採樣計算 Baseline，免除龐大的 Critic Network。

解決方案 – 高斯群體強化適應架構

為解決資源與獎勵駭客問題，我們結合 **參數高效微調 (LoRA)**、**群組相對優化 (GRPO)** 與 **可驗證獎勵 (Verifiable Rule-based Reward)**。

❄ Base Model

Llama-3-8B-Instruct

4-bit Quantized
(凍結 99.8% 參數)

+

LoRA Adapters

注入 Q, V, O, FFN 層

Rank = 16
(僅更新 0.2% 參數
大幅降低梯度顯存)

⇄

⚖ GRPO + Rule Reward

移除 Critic 模型

使用 Nemotron 挑戰賽的
程式/數學絕對驗證
(1.0 對 / 0.0 錯 + 格式分)

系統實作 – 訓練架構設計

1 Data Prep

過濾 Kaggle Nemotron
競賽資料集

10,000 筆高品質
Reasoning 軌跡

2 SFT Warm-up

微調 LoRA 讓模型學會
<think> 標籤格式

Epochs: 2
Max Length: 2048

3 Environment Setup

建立字串正則驗證與
邏輯對錯評分器

Reward: 答案正確(+1)
格式錯誤(-0.5)

4 RL Optimization

執行 GRPO 強化學習
逼出 System 2 推理

Group Size (G): 4
KL Penalty: 0.01

Framework: HuggingFace TRL (v0.12+) **Library:** Peft, BitsAndBytes, vLLM **Hardware Target:** 1x RTX 3090 / 4090 (24GB)

Thank You