基於 LoRA 與強化學習之大型語言模型推理優化

Large Language Model Reasoning Optimization based on LoRA and Reinforcement Learning

[RLHF / GRPO]

[Low VRAM Constraint]

[Parameter-Efficient Fine-Tuning]

Xu-Lin Chen | Jie-En Liu | Xin-Chiao Tien

NotebookLM

01 Introduction (研究動機與挑戰)

02 Related Work (過往研究與對齊技術)

03 Methodology (核心模組與演算法)

04 Proposed Design (系統實作與訓練管線)

NotebookLM

研究動機 - LLM 推理能力的缺失

傳統測試顯示模型數學能力達人類水準，但 GSM-Symbolic 權威研究揭露：模型僅是「背誦模式」(Pattern Matching) ，缺乏真正的 System 2 思考。

標準 GSM8K 測試

94.6%

Llama-3-8B 表面上的數學解題率

變更變數與名字後 (GSM-Symbolic)

- 65%

準確率呈現毀滅性衰退，證明缺乏自我推演能力

* Apple Machine Learning Research (2024) - "Understanding the Limitations of Mathematical Reasoning in LLMs"

NotebookLM

解決方向 - 強化學習的導入

純監督式微調 (SFT) 已觸碰能力天花板。導入強化學習引導模型生成長思維鏈 (Chain-of-Thought) 是唯一能突破複雜邏輯瓶頸的方法。

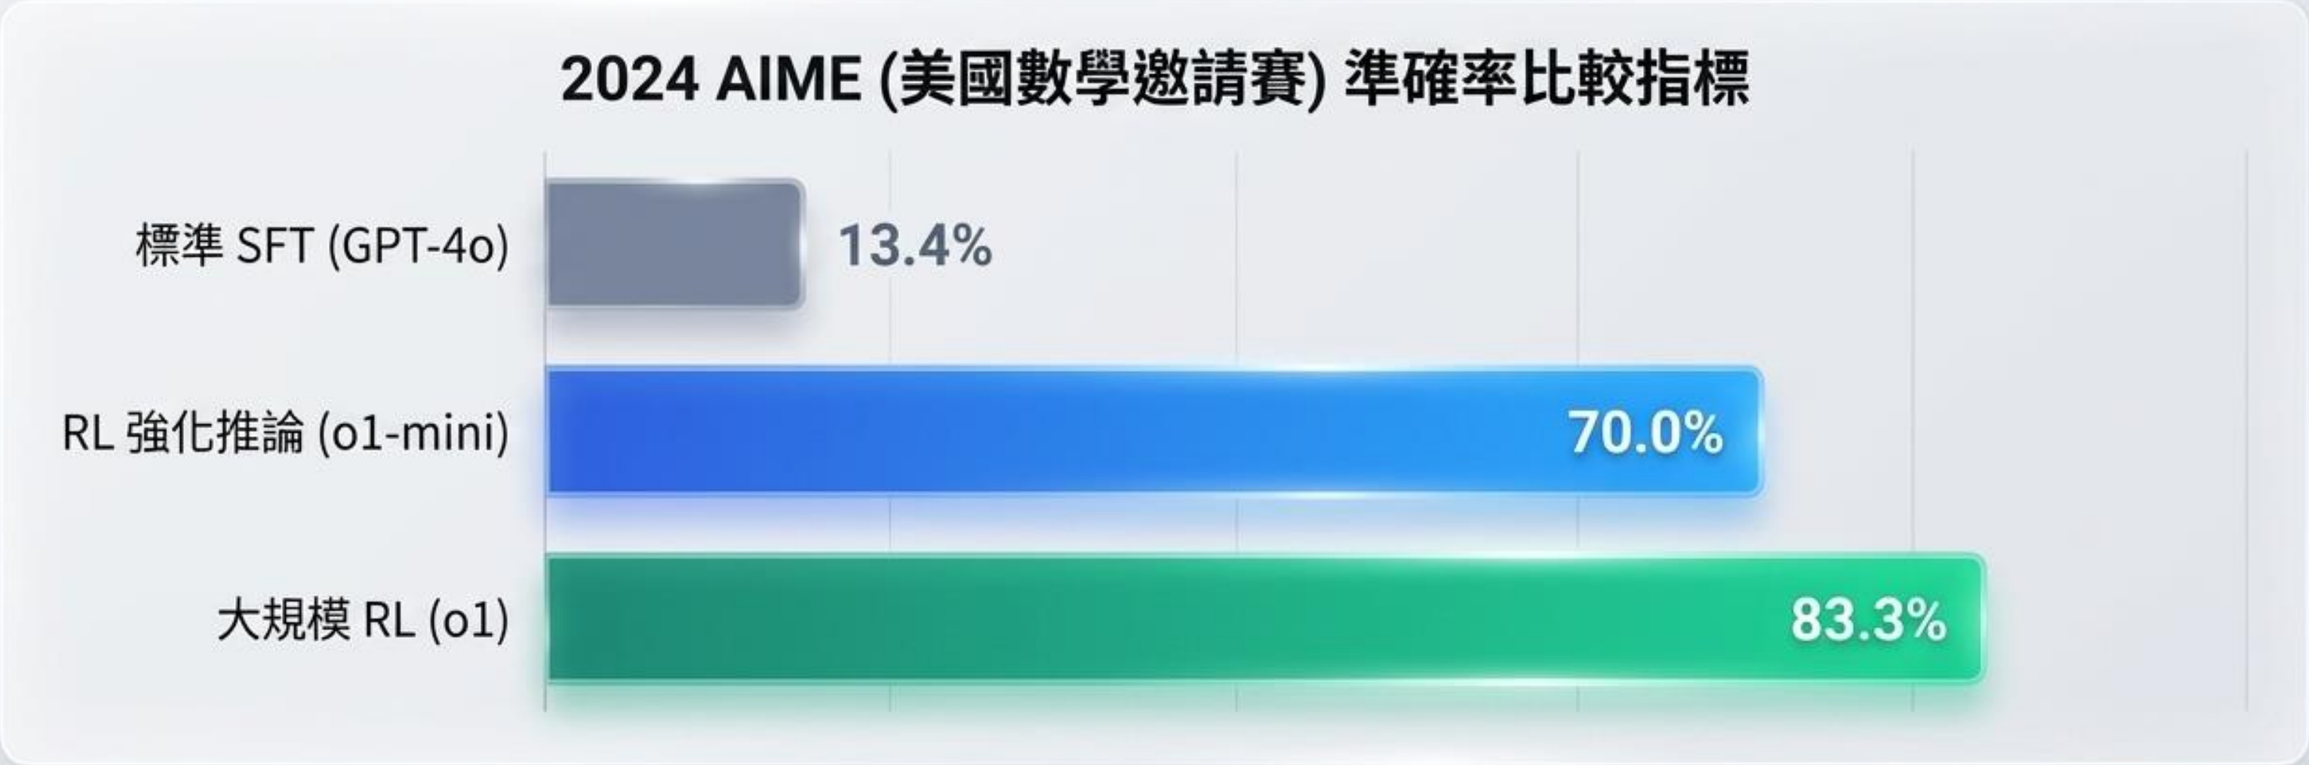

* OpenAI o1 System Card (2024) - AIME 2024 Pass@1 基準測試

NotebookLM

當前挑戰 - 強化學習的硬體限制

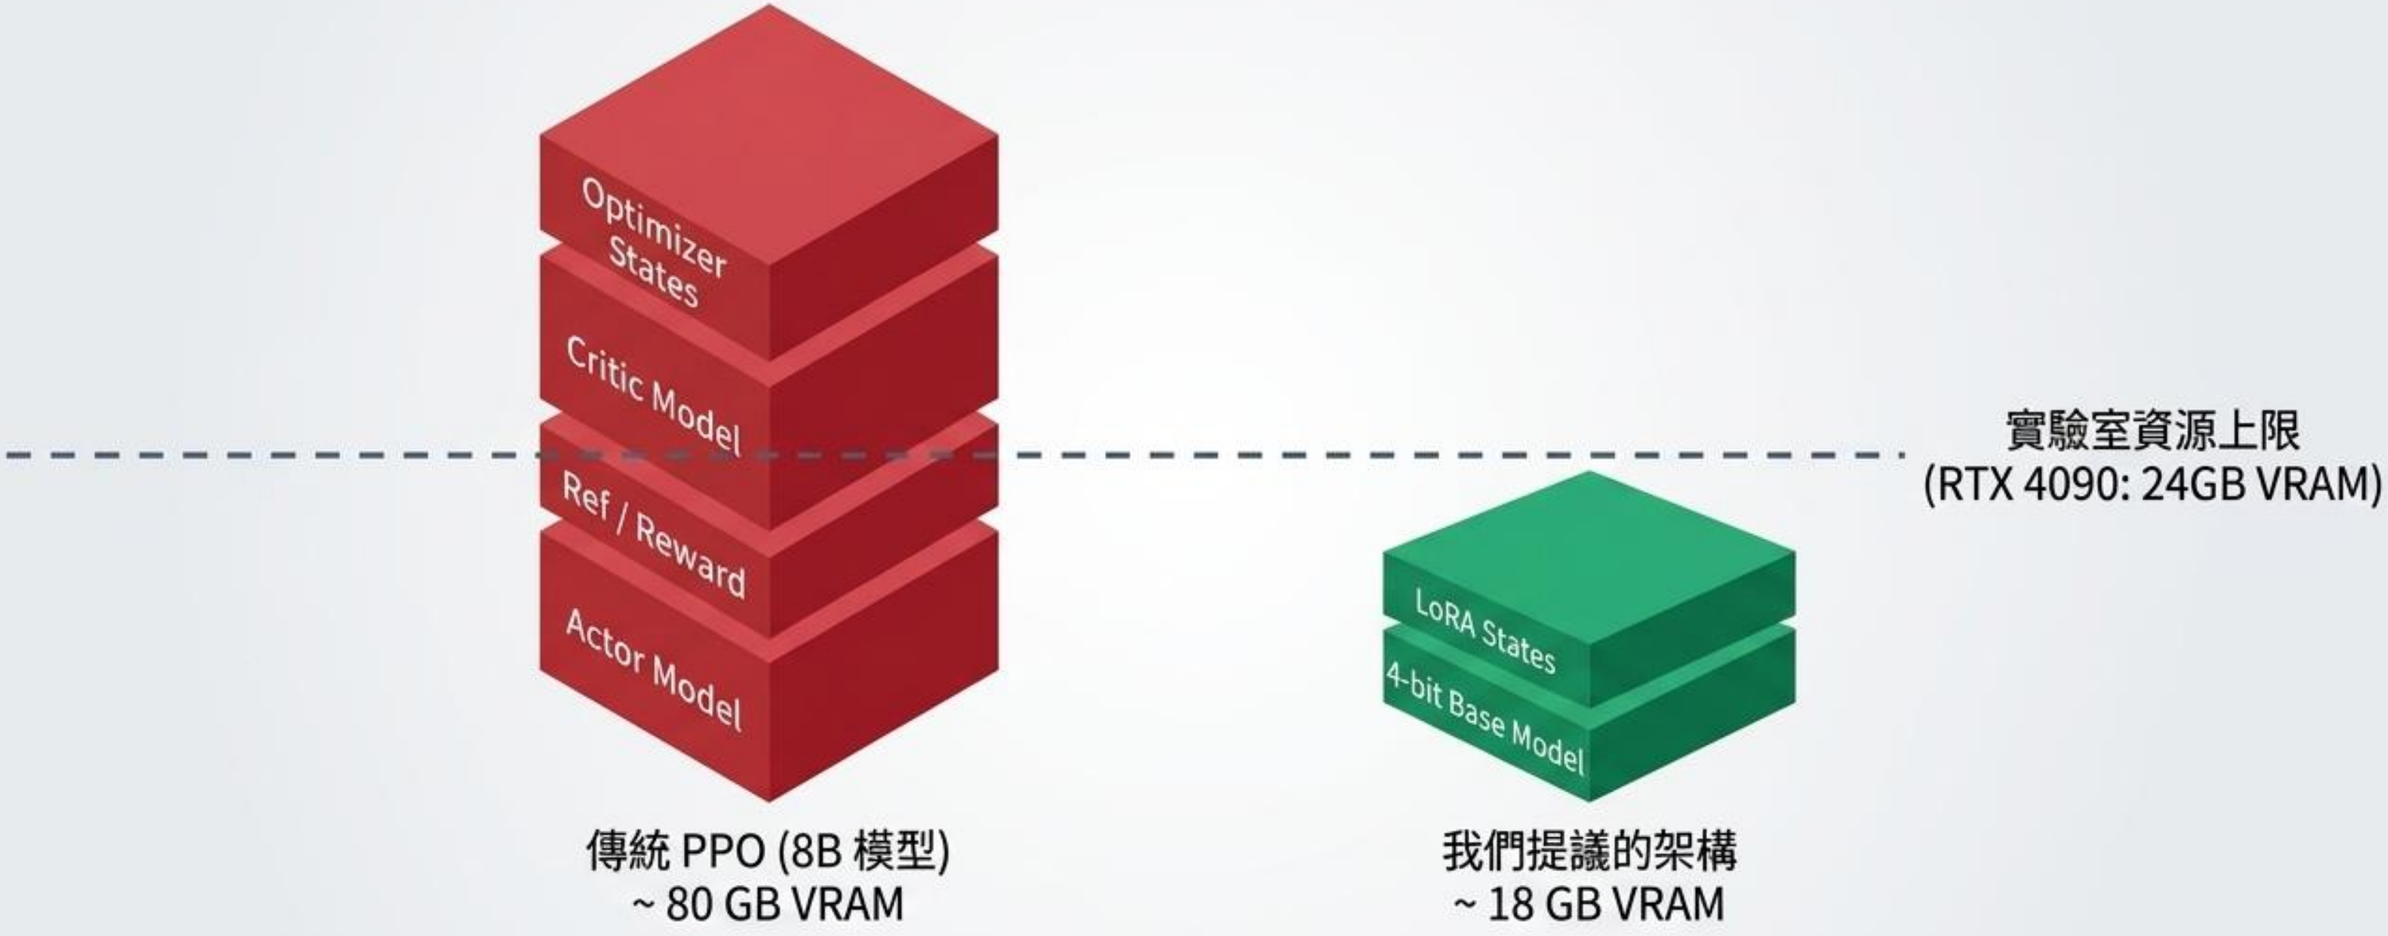

標準 PPO 演算法需同時在顯存中載入 4 個模型。對於 8B 參數模型，全參數微調將完全突破學術實驗室的消費級 GPU 極限。

NotebookLM

當前挑戰 - 獎勵駭客風險 (Reward Hacking)

LLM 作為裁判
(Reward Model)

若依賴 LLM 作為裁判 (Reward Model) 給分，模型極易學會生成「看似合理但邏輯錯誤」的長篇大論來騙取高分。

導致訓練崩潰 (Training Collapse)，模型學會的是「修辭 (rhetoric)」而非「邏輯 (logic)」。

必須消滅神經網路裁判的偏見！

NotebookLM

過往研究 – 主流對齊技術比較

對齊技術 (Alignment)	複雜邏輯推理提升	運算資源 (VRAM需求)	需額外訓練 Reward Model?
SFT (Supervised Fine-Tuning)	低 (易產生幻覺)	低 (單一模型)	否
PPO (Proximal Policy Optimization)	極高	極高 (4個模型)	是 (容易產生 Reward Hacking)
DPO (Direct Preference Opt.)	中等	高 (2個模型)	否 (使用離線成對數據)
Ours: GRPO + LoRA + Rule Reward	極高 (具備自我回溯與探索)	極低 (凍結主幹 + 無 Critic)	否 (直接使用程式/規則驗證)

* GRPO (Group Relative Policy Optimization) 參考自 DeepSeek-R1 (2025)，透過同一 Prompt 多次採樣計算 Baseline，免除龐大的 Critic Network。

NotebookLM

解決方案 – 高斯群體強化適應架構

為解決資源與獎勵駭客問題，本專案完美結合三大核心技術。

Base Model

Llama-3-8B-Instruct

4-bit Quantized
(凍結 99.8% 參數)

+

LoRA Adapters

注入 Q, V, O, FFN 層

Rank = 16
(僅更新 0.2% 參數)

GRPO + Rule Reward

移除 Critic 模型

絕對邏輯驗證
(1.0 絕對對 / 0.0 絕對錯)

NotebookLM

核心模組一：基礎模型與 4-bit 量化

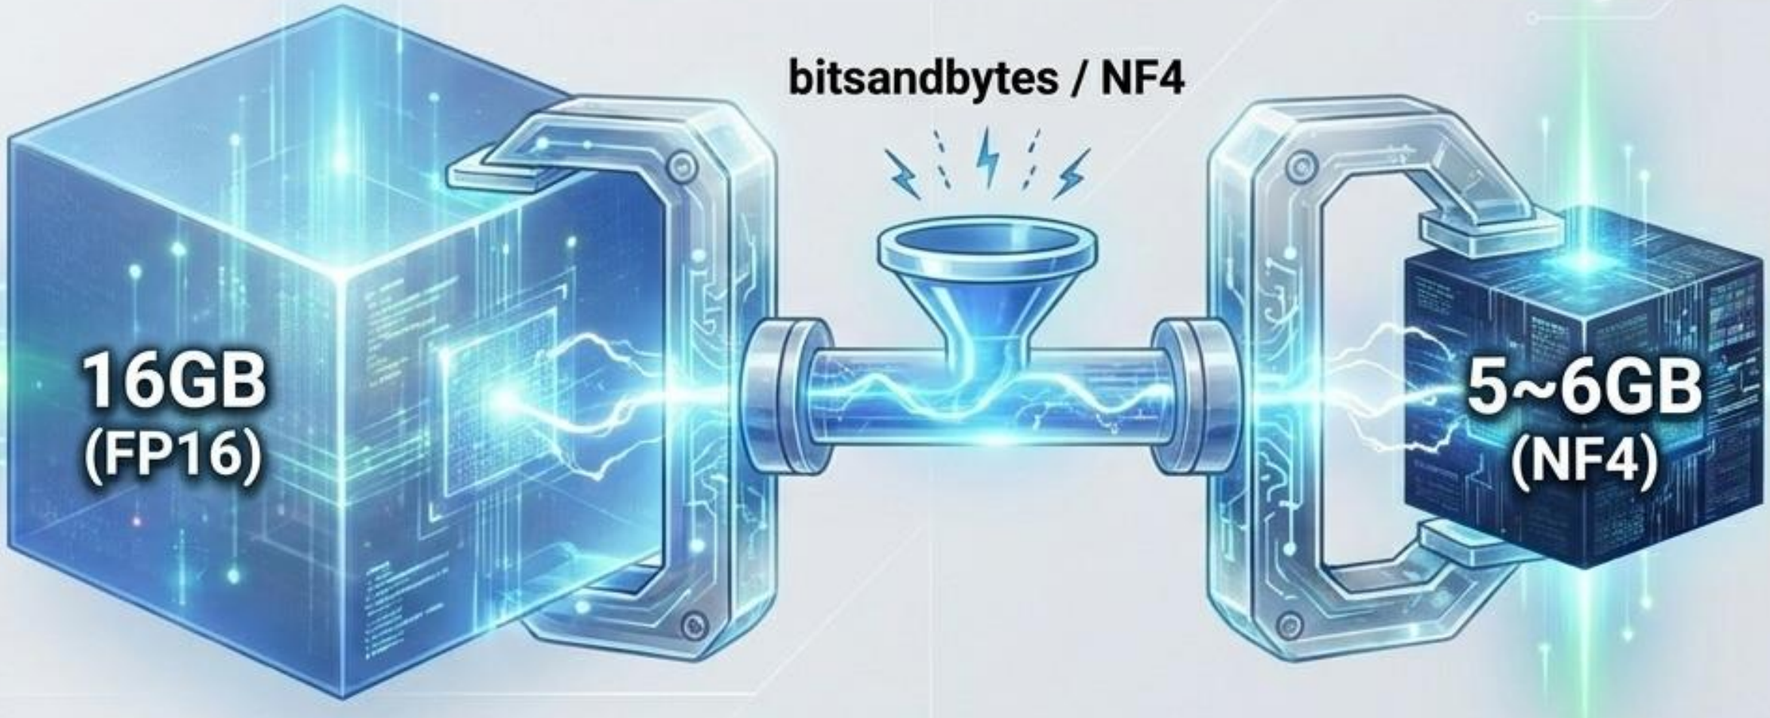

- **Component**: Llama-3-8B-Instruct (或 NVIDIA Nemotron-3-Nano-8B)
- **Mechanism**: 採用 NF4 (NormalFloat 4-bit) 量化技術載入模型，並開啟 double_quantization。
- **Technical Impact**: 將 8B 模型原本約需 16GB 的權重顯存佔用，大幅壓縮至 5~6 GB，為後續的 RL 生成採樣與梯度計算 (vLLM) 保留充足的 VRAM 空間。

NotebookLM

核心模組二：參數高效微調 (PEFT - LoRA)

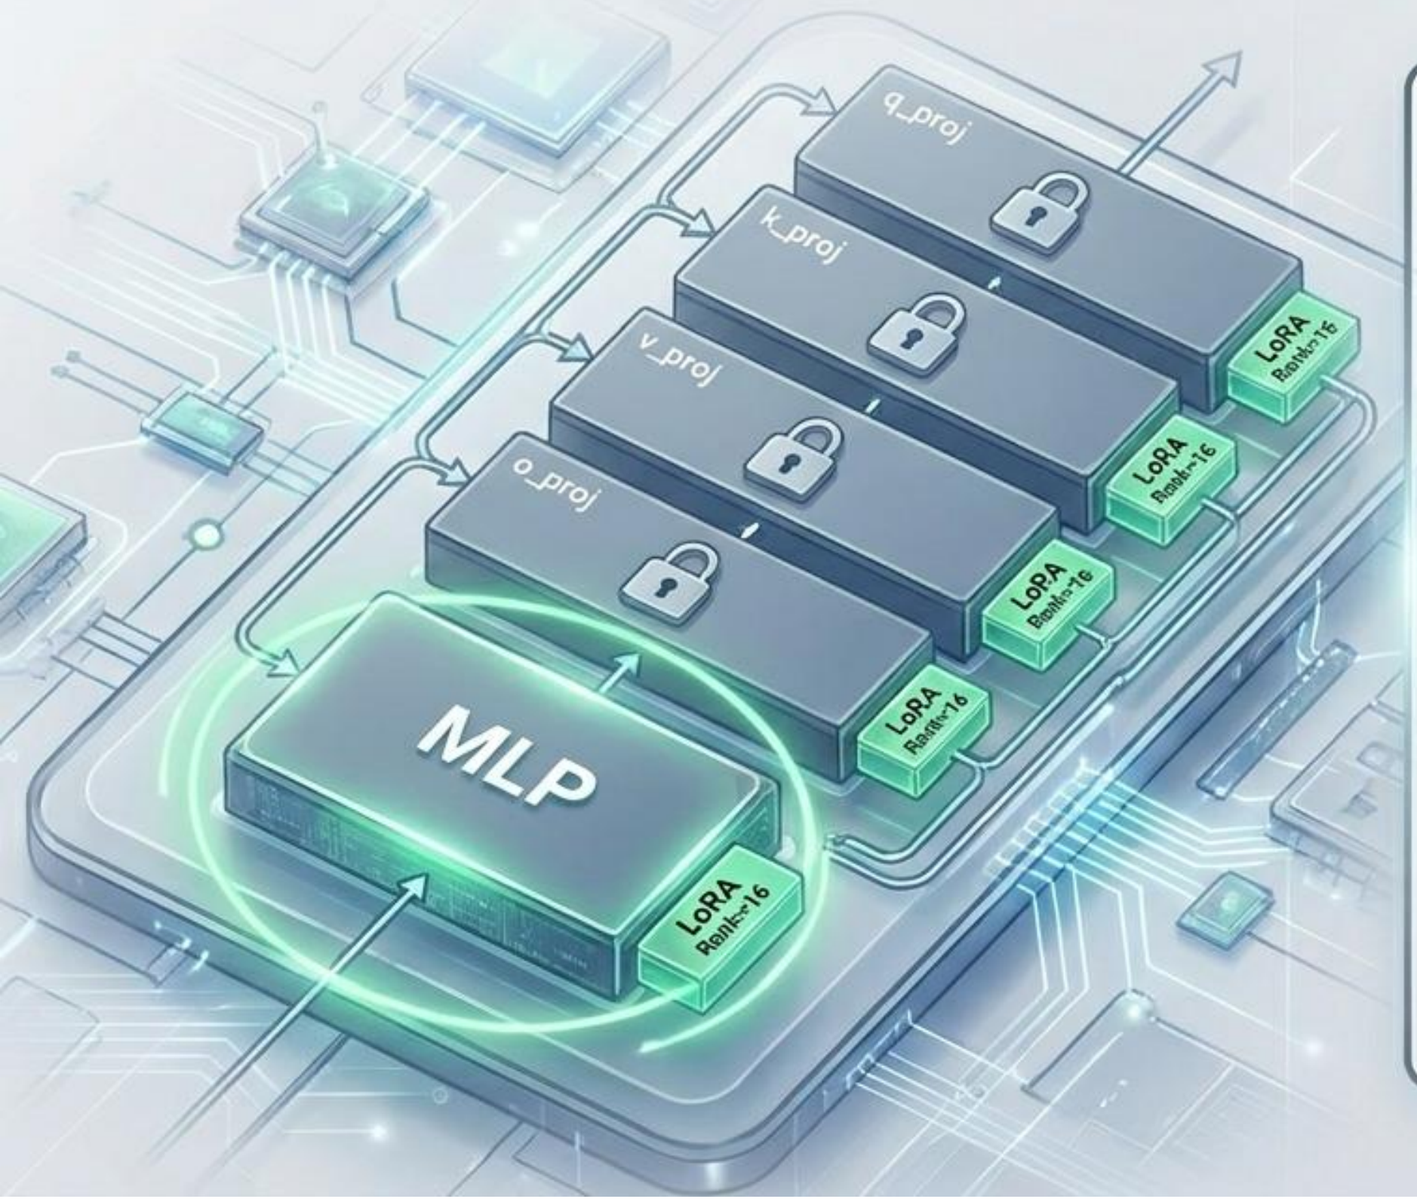

- **Mechanism:** 在凍結預訓練模型的主幹權重下，將低秩矩陣掛載於注意力機制與前饋網路中。
- **Target Modules:** q_proj, k_proj, v_proj, o_proj, 以及關鍵的 MLP 層 (gate_proj, up_proj, down_proj)。
- **Key Insight:** 覆蓋 MLP 層是關鍵，模型的邏輯與知識重構大多發生於此。
- **Resource Efficiency:** Rank=16, Alpha=32。可訓練參數小於總參數的 0.3% (~20M)，極大化梯度更新效率。

NotebookLM

核心模組三：可驗證規則獎勵 (RLVR)

捨棄 LLM 作為 Reward Model，徹底根絕獎勵駭客。直接透過程式碼編譯器或字串匹配給予絕對的二元獎勵。

NotebookLM

核心模組四：GRPO 演算法 (Group Relative Policy Optimization)

$$A_i = \frac{R_i - \text{mean}(R)}{\text{std}(R)}$$

Mechanism
對同一個問題採樣多個輸出 (G=4~8)，在群體內部計算優勢函數 (Advantage)，完全消除對 Critic Network 的依賴。

Safety Net
導入 KL 散度懲罰 (KL Penalty)，防止模型在追求高分的過程中過度偏離原始語言分佈而失去連貫性。

NotebookLM

系統實作 – 訓練管線
第一階段：SFT Warm-up

1

Data Prep

過濾 Kaggle Nemotron 競賽資料集。精選 10,000 筆高品質 Reasoning 軌跡。

10,000 筆高品質 Reasoning 軌跡

2

SFT Warm-up

目標：讓基礎模型學會「先思考、再回答」的文本結構（學會使用 <think> 標籤）。
設定：Epochs = 2。
產出：為後續 RL 提供具備基礎格式的 Base Policy。

Epochs: 2, Max Length: 2048

3

Environment Setup

目標：讓基礎模型學會「先思考、再回答」的文本結構（學會使用 <think> 標籤）。
設定：Epochs = 2。

4

RL Optimization

目標：讓基礎模型學會「先賽資料集。精選 10000 Fleasoing 生擴高品質軌跡）。

Framework: HuggingFace TRL (v0.12+) **Library:** Peft, BitsAndBytes, vLLM **Hardware Target:** 1x RTX 3090 / 4090 (24GB)

NotebookLM

系統實作 – 訓練管線
第二階段：RL Optimization

1 Data Prep

2 SFT Warm-up

3 **Environment Setup**

建立字串正規絡驗證與邏輯對錯評分器。設定絕對獎勵：正確 (+1) ，格式錯誤 (-0.5)。

4 **RL Optimization**

Framework: HuggingFace TRL (v0.12+) **Library:** Peft, BitsAndBytes, vLLM **Hardware Target:** 1x RTX 3090 / 4090 (24GB)

NotebookLM

預期技術突破與結論 (Expected Technical Breakthroughs)

運算資源的極限壓縮
(Extreme Resource Compression)

成功將需 80GB VRAM 的完整 RLHF 流程，透過 4-bit Base + LoRA + GRPO 聯合設計，壓縮至至 18GB - 20GB。首次證明單張消費級 GPU 執行 RL 邏輯對齊的可行性。

根絕模型崩潰與幻覺
(Eradicating Hallucination & Hacking)

放棄神經網路裁判，改採 Rule-based 可驗證獎勵。消除評分偏見，迫使模型只能透過「真正提升邏輯嚴謹度」來獲取高分。

湧現自我修正能力
(Emergence of System 2)

預期模型會在 <think> 區塊內展現出「等等，這算錯了，讓我重新計算」的自我回溯與修正行為，達成單純 SFT 無法實現的真正深層推理。

Thank You

NotebookLM