2. 相關文獻 (Related Work)

本研究旨在透過資源受限的硬體環境，利用強化學習提升大型語言模型（LLM）的複雜推理能力。本節將回顧與本專案密切相關的三大研究領域：(1) 大型語言模型推理能力的激發與限制；(2) 強化學習在模型對齊與推理上的應用演進；(3) 參數高效微調（PEFT）技術的發展。

2.1 大型語言模型推理能力的激發與限制

近年來，語言模型在常識問答與文本生成上取得了巨大成功，但面對複雜的數學、邏輯推演與程式除錯時，傳統的端到端生成往往力有未逮。

思維鏈（Chain-of-Thought, CoT）的崛起： Wei et al. (2022) 提出了思維鏈提示技術，證實透過引導模型在給出最終答案前，先生成一系列中間推理步驟，能顯著提升其在 GSM8K 等邏輯基準測試上的表現。後續研究如 Tree of Thoughts (Yao et al., 2023) 進一步將線性推理擴展為樹狀搜尋，增強了多步驟規劃能力。

監督式微調（SFT）的隱憂與推理幻覺： 儘管許多開源模型透過收集高質量的 CoT 軌跡進行監督式微調（SFT）以模仿推理過程，但 Apple 團隊的最新研究 GSM-Symbolic (Imani et al., 2024) 嚴厲指出：純粹依賴 SFT 的語言模型往往只是在進行「模式匹配（Pattern Matching）」與「記憶背誦」。當測試題目的數字或名詞被替換，或是加入無關緊要的干擾條件時，主流模型的準確率會出現災難性的衰退（高達 65% 的降幅）。這表明單純的 SFT 無法讓模型具備真正的「系統二（System 2）」抽象邏輯演繹能力。近期 OpenAI 的 o1 模型技術報告 (OpenAI, 2024) 亦證實，唯有透過強化學習，才能真正賦予模型在推論期（Test-time）進行自我驗證與除錯的能力。

2.2 從人類回饋到規則驅動的強化學習

強化學習（RL）是使 LLM 行為符合人類預期（Alignment）的核心技術，其在推理任務上的應用正經歷典範轉移。

傳統 RLHF 與 DPO 的侷限： InstructGPT (Ouyang et al., 2022) 確立了基於人類回饋的強化學習（RLHF）框架，利用 PPO (Proximal Policy Optimization) 演算法優化策略網路。然而，PPO 需要同時維護四個模型（Actor, Critic, Reward, Reference），硬體成本極高。隨後，Rafailov et al. (2023) 提出的直接偏好優化（DPO）透過將獎勵模型隱式化，大幅簡化了訓練流程。但 DPO 本質上是一種離線學習（Offline Learning），缺乏讓模型主動「探索」錯誤並從中學習的機制，因此在需要長推論軌跡的數學與邏輯任務上，表現遠不及在線（Online）的強化學習。

獎勵駭客與可驗證獎勵（Verifiable Rewards）： 在使用神經網路作為獎勵模型（Reward Model）時，LLM 極易發生「獎勵駭客（Reward Hacking）」現象——即學會生成冗長且看似專業，但邏輯完全錯誤的文字來騙取高分。為解決此問題，NVIDIA Nemotron 團隊以及 DeepSeekMath (Shao et al., 2024) 等研究轉向使用「基於規則與執行器的可驗證獎勵」。在數學或程式任務中，直接透過程式碼編譯器或字串匹配給予絕對的二元獎勵（正確為 1，錯誤為 0），徹底消除了神經網路裁判的偏見。

群組相對策略優化（GRPO）： 為了解決 PPO 龐大的顯存消耗，DeepSeek-R1 等最新研究採用了 GRPO (Group Relative Policy Optimization)。該演算法捨棄了與模型同等大小的 Critic Network，

改為針對同一個 Prompt 採樣多個輸出，並在群組內部計算相對優勢（Advantage）。這不僅大幅降低了 VRAM 需求，也提高了訓練的穩定性，成為本專案架構設計的重要基石。

2.3 資源受限下的參數高效微調 (PEFT)

要在學術實驗室或 Kaggle 競賽的單卡 GPU（如 24GB VRAM）上對 8B 甚至更大參數的模型進行強化學習，全參數微調是不切實際的。

LoRA (Low-Rank Adaptation)： Hu et al. (2021) 提出的 LoRA 技術，透過凍結預訓練模型的主幹權重，並在注意力層（Attention Layers）旁注入可訓練的低秩矩陣。由於秩（Rank）通常設為極小值（如 8 或 16），可將需要更新的參數數量減少 10,000 倍，同時將 GPU 顯存需求降低 3 倍以上。

PEFT 與 RL 的結合： 近期的研究開始探索將 LoRA 應用於 RLHF 階段。然而，多數開源實作仍停留在 DPO + LoRA 的層次。本專案借鑑最新文獻，提出將 LoRA 掛載於 Actor 模型上，並配合 GRPO 演算法與可驗證獎勵（針對 NVIDIA Nemotron 數據集），以極低的運算成本建立一個完整的「在線探索式」強化學習迴圈。此架構預期能彌補單純 SFT 在複雜推理任務上的致命缺陷。

小結與本研究定位 (Summary & Positioning)

綜上所述，現有文獻顯示：**SFT 擅長賦予模型格式，但 RL 才是激發深層邏輯推理的關鍵**。本研究提案結合了上述三大領域的前沿技術，定位如下表所示：

技術方法	邏輯推理提升能力	獎勵駭客風險	運算資源需求 (VRAM)	本專案採用
SFT (監督微調)	低 (易淪為模式背誦)	無	低 (單一模型)	階段一 (Warm-up)
PPO + 神經獎勵模型	高	高 (容易騙取分數)	極高 (需 4 個模型)	否
DPO	中	低 (離線靜態數據)	高 (需 2 個模型)	否
GRPO + LoRA + 可驗證獎勵	**極高 (具備自我回溯與探索)**	**極低 (絕對規則評分)**	**極低 (無 Critic 且凍結主幹)**	**核心階段 (RL 優化)**

本專案期望透過 Kaggle 的 NVIDIA Nemotron 挑戰賽，實證在消費級硬體上，透過上述輕量化 RL 組合，亦能引導模型湧現出類似 OpenAI o1 的強大 System 2 推理能力。